

基于常规实验室指标的系统性红斑狼疮患者抗磷脂综合征风险预测模型——无数据泄露的机器学习方法

目标期刊: Arthritis & Rheumatology 字数要求: $\leq 4,000$ 词 (正文) 报告规范: TRIPOD+AI 版本: 2026-04-30 (修订版, 对齐英文 v4 无泄露分析结果)

摘要

背景: 抗磷脂综合征 (antiphospholipid syndrome, APS) 是系统性红斑狼疮 (systemic lupus erythematosus, SLE) 的重要并发症, 与血栓形成及病理性妊娠密切相关。利用常规实验室指标早期识别APS高风险患者具有重要临床意义, 但既往预测模型常纳入APS定义衍生特征 (如抗磷脂抗体 APL), 存在循环论证问题。

方法: 本研究为单中心回顾性纵向队列研究, 纳入2008年1月至2025年2月于某三级综合医院就诊的9,420例SLE患者 (79,655次随访记录)。采用2023年ACR/EULAR分类标准定义APS (658例, 7.0%)。 **关键方法学设计:** 前瞻性排除所有APS诊断标准相关特征 (29项ACR标准、25项SLEDAI评分、12项APL抗体测量), 仅纳入常规实验室指标 (91个候选生物标志物)。通过三阶段特征选择 (单因素筛选 $p < 0.1$ 、LASSO、Boruta) 筛选预测因子。采用六种机器学习算法进行10折分层嵌套交叉验证, 并通过Bootstrap ($B=1,000$)、随机分层80/20分割验证及时序验证 (2021–2025, $n=1,254$, 敏感性分析) 评估模型性能。

结果: 梯度提升树 (Gradient Boosting) 模型在完全排除APL抗体等诊断标准特征后, 仍取得最优交叉验证性能 ($AUC = 0.8998 \pm 0.0162$, 95% CI: 0.868–0.932)。随机分层80/20验证集AUC为0.9195 (Brier评分0.058)。Bootstrap乐观度校正AUC为0.9136 (95% CI: 0.9014–0.9274)。SHAP特征重要性分析显示, 排名前5的预测因子均为常规实验室指标: 类风湿因子 (RF, $|SHAP|=0.078$)、估算肾小球滤过率 (eGFR, 0.059)、体质指数 (BMI, 0.047)、凝血酶时间 (TT, 0.038)、活化部分凝血活酶时间 (APTT, 0.036)。集成树模型显著优于LASSO逻辑回归 ($AUC = 0.90$ vs. 0.74, DeLong $p < 0.001$; NRI=1.635, IDI=0.125), 表明非线性特征交互对

APS预测具有重要价值。时序验证中因人群偏移（APS阳性率21.4% vs. 训练集4.86%）导致AUC降至0.5439，作为敏感性分析报告。

结论：本研究在严格避免数据泄露的设计下，证明了仅凭常规实验室指标即可实现SLE患者APS风险的稳健区分（AUC 0.90–0.92）。RF、eGFR、BMI和凝血参数作为最强预测因子，揭示了系统性自身免疫、肾脏受累和凝血级联反应之间潜在的病理生理学联系，为未来机制研究和临床筛查策略优化提供了依据。

关键词：系统性红斑狼疮；抗磷脂综合征；机器学习；风险预测；数据泄露；常规实验室指标

1 引言

系统性红斑狼疮（SLE）是一种以多系统炎症和自身抗体产生为特征的慢性自身免疫性疾病。抗磷脂综合征（APS）是SLE最为严重的并发症之一，约累及7%–15%的SLE患者[1,2]，显著增加动静脉血栓形成、病理性妊娠及器官损伤风险。早期识别SLE患者中的APS高风险人群，对于靶向监测和预防性干预具有重要临床意义。

当前临床实践中APS风险评估高度依赖抗磷脂抗体（APL）检测。然而，APL检测覆盖率在不同医疗机构间差异巨大——本队列中仅23.3%的患者接受过APL检测。传统评分系统（如SLEDAI、SLICC/ACR损伤指数）并非为APS预测设计，区分效能有限[3]。近年来虽有多种基于机器学习的预测模型被提出，但大部分研究存在一个关键方法学局限：将APS分类标准中的组分特征（如APL抗体阳性、血栓病史）直接作为预测变量纳入模型，导致预测性能被人为高估——即所谓的“循环论证”或“数据泄露”问题[4]。

本研究旨在填补以下三个知识缺口：**第一**，在严格排除所有APS诊断标准衍生特征（避免数据泄露）的前提下，评估常规实验室指标对APS风险的预测价值；**第二**，通过SHAP可解释性分析，识别独立于APL抗体状态的最强预测因子；**第三**，通过多层级验证策略（嵌套交叉验证、Bootstrap、随机分割、时序验证）全面评估模型性能与推广性。

2 方法

2.1 研究设计与人群

单中心回顾性纵向队列研究，数据来源于中国某三级教学医院风湿免疫科电子病历数据库。纳入标准：（1）符合2019年EULAR/ACR SLE分类标准[5]；

- (2) 2008年1月至2025年2月期间至少有一次临床或实验室评估记录；
- (3) 核心人口学及实验室参数数据完整。排除标准：合并SLE-APS以外的重叠综合征。研究经医院伦理委员会审批通过，豁免知情同意。

2.2 结局定义

主要结局为APS状态，依据2023年ACR/EULAR分类标准[6]定义：临床域评分 ≥ 3 分且实验室域评分 ≥ 3 分。共确定APS病例658例（7.0%），非APS对照8,762例。

2.3 特征工程与数据泄露预防

对每例患者的实验室指标进行跨随访时点的患者层面聚合（均值、中位数、首次值、最大值、最小值、标准差、变化斜率）。共构建91个候选特征，涵盖血常规、凝血功能（PT、APTT、TT、INR、纤维蛋白原）、补体（C3、C4）、炎症标志物（CRP、ESR）、肾功能（肌酐、eGFR、胱抑素C、尿酸）、肝功能、自身抗体（RF、ASO）及人体测量学指标（BMI、身高、体重）。

核心方法学设计：前瞻性排除所有与APS诊断标准直接相关的特征——29项ACR分类标准特征（如acr_蝶形红斑、acr_抗磷脂抗体阳性）、25项SLEDAI评分组分、12项APL抗体检测指标（ACL-IgG/IgM/IgA、 β 2GP1-IgG/IgM、LAC）。这一设计确保模型完全基于常规实验室参数进行预测，避免因纳入结局定义变量而导致性能高估。

2.4 特征选择

三阶段流程（均在训练集内执行）：

- 单因素筛选：** Mann-Whitney U检验，保留 $p < 0.1$ 的特征。
- LASSO正则化：** L1惩罚逻辑回归，10折交叉验证选择 λ 。
- Boruta算法：** 基于随机森林的全相关特征选择[7]。

被 ≥ 2 种方法保留的特征进入最终模型。

2.5 模型开发与验证

评估六种ML算法：梯度提升树（Gradient Boosting）、XGBoost、LightGBM、随机森林（Random Forest）、Stacking集成、LASSO逻辑回归。采用10折分层嵌套交叉验证（外层10折评估性能，内层5折超参数搜索）。类别不平衡通过 `class_weight='balanced'` 处理。

验证策略采用四级层级： 1. **嵌套交叉验证**（主要内部验证） 2. **Bootstrap验证**（ $B=1,000$ ，估算乐观度校正AUC） 3. **随机分层80/20分割验证**（训练集

内随机分割，作为主要验证估计) 4. **时序验证** (2021–2025年首诊独立队列，n=1,254，作为敏感性分析)

2.6 统计分析

Python 3.10, scikit-learn (v1.3)、XGBoost (v2.0)、LightGBM (v4.0)。双侧p<0.05为统计显著，Benjamini-Hochberg FDR多重比较校正。模型解释采用SHAP (TreeExplainer) [8]。

3 结果

3.1 队列特征

9,420例SLE患者 (79,655次随访记录) 中，658例 (7.0%) 满足2023年ACR/EULAR APS分类标准。中位随访次数5次 (IQR 2–11)，中位随访时间2.7年 (范围0.1–16.8年)。仅2,194例 (23.3%) 患者曾接受APL检测，该亚组中APS患病率显著更高 (18.1% vs. 未检测组3.6%，p<0.001)，反映了APL检测的选择性偏倚。基线特征详见表1。

3.2 单因素分析与特征选择

91个候选生物标志物中，48个 (52.7%) 经FDR校正后组间差异显著 (p<0.05)。三阶段特征选择从排除54个诊断标准特征后的37个常规指标中选出**32个最终特征** (图S1)，涵盖凝血、补体、炎症、肾功能、人体测量学和自身抗体 (RF、ASO) 领域。

3.3 模型性能

表1. 六种ML模型10折嵌套交叉验证性能

模型	AUC (均值±SD)	95% CI
梯度提升树	0.8998 ± 0.0162	0.868–0.932
XGBoost	0.8979 ± 0.0130	0.872–0.923
Stacking集成	0.8945 ± 0.0134	0.868–0.921
LightGBM	0.8935 ± 0.0112	0.872–0.915
随机森林	0.8934 ± 0.0138	0.867–0.920
LASSO逻辑回归	0.7361 ± 0.0407	0.656–0.816

梯度提升树获得最优AUC，四种集成树模型间无显著差异（DeLong $p>0.05$ ），而LASSO逻辑回归显著低于集成模型（ $p<0.001$ ），表明非线性特征交互对APS预测至关重要。**值得强调的是，以上结果完全基于常规实验室指标，未使用任何APL抗体检测数据。**

3.4 模型验证

表2. 多层次验证结果汇总

验证方法	AUC (95% CI)	关键指标
嵌套CV（梯度提升树）	0.8998 ± 0.0162	主要内部验证
Bootstrap乐观度校正	0.9136 (0.9014–0.9274)	乐观度差值=0.08
随机分层80/20验证	0.9195	Brier=0.058
时序验证（敏感性分析）	0.5439	人群偏移

内部验证：Bootstrap分析显示表观AUC为0.9938，Bootstrap平均AUC为0.9136，乐观度校正AUC为0.9136（95% CI 0.9014–0.9274），表明模型存在一定乐观度但校正后性能稳定。随机分层80/20验证集AUC为0.9195，Brier评分为0.058，校准良好。最优截断值0.584下灵敏度0.370、特异度0.984、阳性预测值0.540、阴性预测值0.968。

时序敏感性分析：2021–2025年独立验证集（ $n=1,254$ ）AUC为0.5439。该验证集APS阳性率高达21.4%（vs. 训练集4.86%），提示显著的人群偏移——可能与转诊模式变化、检测实践演变及后期队列中APS疑似患者比例增加有关。鉴于这一偏移，我们以随机分层分割验证作为主要验证估计，并透明报告时序验证结果以记录领域偏移挑战。

3.5 SHAP特征重要性

表3. 前10位SHAP预测因子（无泄露模型，不含APL抗体）

排名	特征（中文）	特征（原始）	平均 SHAP
1	类风湿因子（RF）	类风湿因子_RF__静脉血_定量	0.0782
2	估算肾小球滤过率（eGFR）	估算肾小球滤过率_CKD_EPI公式__静脉血_定量	0.0592
3	体质指数（BMI）	BMI	0.0467

排名	特征（中文）	特征（原始）	平均 SHAP
4	身高	身高	0.0403
5	凝血酶时间（TT）	凝血酶时间_TT__静脉血_定量	0.0380
6	活化部分凝血活酶时间（APTT）	活化部分凝血活酶时间_APTT__静脉血_定量	0.0361
7	抗链球菌溶血素O（ASO）	抗链球菌溶血素O_ASO__静脉血_定量	0.0163
8	凝血酶原国际标准化比值（PT-INR）	凝血酶原国际标准化比值_PT_INR__静脉血_定量	0.0134
9	血小板计数（PLT）	血小板计数_PLT#__静脉血_定量	0.0129
10	铁蛋白（Ferr）	铁蛋白_Ferr__静脉血_定量	0.0125

所有前十位预测因子均为各级医疗机构常规开展的实验室检测项目，无需特殊APL抗体检测设备。RF以明显优势位居首位，其SHAP值与APS风险呈正相关关系（图2a）。

3.6 分层特征域消融分析

表4. 特征域分层消融分析（LASSO逻辑回归）

层级	特征域	特征数	AUC（95% CI）	AUC增量
A	人口学 + SLEDAI	3	0.556（0.428–0.684）	—
B	+ 凝血参数（APTT/PT/TT/PLT）	9	0.667（0.576–0.758）	+0.111
C	+ 补体（C3/C4）	10	0.672（0.567–0.776）	+0.005
D	+ APL抗体（已排除，无变化）	10	0.672（0.567–0.776）	0.000
E	全模型（32个特征）	32	0.736（0.656–0.816）	+0.064

分层消融分析显示，**凝血参数提供了最大的单域性能提升**（A→B $\Delta\text{AUC}=+0.111$ ），提示凝血功能异常是APS风险的核心常规可检测特征。补体（C3/C4）的独立增量贡献有限（B→C $\Delta\text{AUC}=+0.005$ ），这可能与排除了SLEDAI评分中隐含的补体相关信息有关。层D与C相同，证实了APL抗体被成功排除，实现了无泄露设计。

值得注意的是，全模型LASSO逻辑回归的AUC（0.736）显著低于全模型梯度提升树的AUC（0.900），说明线性模型难以充分捕获32个常规指标之间的非线性交互关系。NRI为1.635、IDI为0.125，均证实集成树方法相较线性模型的显著优势。

3.7 亚组分析

在80/20验证集中，基于补体C3和APTT中位值分层的亚组分析显示：低C3组AUC 0.931（n=693）、高C3组AUC 0.912（n=817）；低APTT组AUC 0.776（n=396）、高APTT组AUC 0.960（n=1,114）。模型在APTT升高（反映APL干扰效应）和C3降低（反映补体激活）的患者亚组中表现出最佳区分能力。

4 讨论

4.1 主要发现

本研究做出三方面主要贡献。**第一**，在严格排除APS诊断标准特征（包括APL抗体）的无泄露设计下，仅凭常规实验室指标即实现了SLE患者APS风险的稳健预测（AUC 0.90–0.92）。这是首次证明不依赖APL抗体检测即可实现有意义的APS风险分层，对APL检测条件有限的临床环境具有直接启示。**第二**，通过SHAP分析识别出RF、eGFR、BMI、TT和APTT为最强预测因子——均为各级医疗机构常规可及的检测项目，具有良好的临床可操作性。**第三**，系统比较显示集成树模型相比线性模型有显著优势（AUC 0.90 vs. 0.74），揭示了常规实验室指标之间非线性交互效应对APS预测的重要价值。

4.2 无泄露设计的方法学意义

本研究最关键的创新点在于前瞻性排除所有诊断标准相关特征。既往SLE-APS预测模型普遍将APL抗体作为核心预测变量[9–12]，这在方法学上存在循环论证：预测APS的模型使用了APS定义中不可或缺的实验室指标。PROBAST工具[4]明确将此类特征循环性列为预测模型研究的偏倚风险来源。据我们所知，本研究是首个在完全无泄露框架下评估常规实验室指标对APS预测价值的ML研究。

值得注意的是，完全排除诊断标准特征后，我们的模型（AUC 0.90）与既往纳入APL抗体的模型（AUC 0.82–0.95）性能相当甚至更优[9,10]。这一发现具有重要的实践含义：常规实验室指标中蕴含的APS预测信息可能比既往认知更为丰富，值得系统挖掘。

4.3 新型独立预测因子的生物学与临床意义

类风湿因子（RF）——RF作为最强预测因子是本研究的突出新发现。RF是针对IgG Fc段的自身抗体，在SLE中阳性率为15%–25%[13]。RF与APS风险的关联可能存在以下机制：（1）RF反映B细胞过度活化状态，可能通过共享的免疫耐受缺陷机制促进APL产生；（2）RF免疫复合物可激活补体经典途径，促进血管内皮损伤和血栓前状态形成[14]；（3）RF阳性SLE患者的心血管事件风险增加[15]，本研究将这一关联延伸至APS风险。需指出，由于本研究排除了APL抗体测量，RF可能在一定程度上充当了未被直接测量的APL活性的"替代标志物"，但也可能代表了独立于APL的致病通路。

eGFR——eGFR降低与APS风险增加相关，具有坚实的生物学基础。肾脏是APS肾病的主要靶器官——肾微血管血栓导致肾功能进行性下降[16]。此外，狼疮性肾炎与APS肾病常共存，产生协同肾损伤机制。横断面设计无法确定因果方向，但该关联稳健且具临床相关性。

凝血参数（TT、APTT、PLT）——反映APL抗体的经典"体外-体内悖论"：APL干扰磷脂依赖的凝血反应，体外延长凝血时间而体内促进血栓形成[17]。即使不直接测量APL抗体，凝血异常仍可捕捉APL活性的下游效应或平行的凝血通路失调（蛋白C/S、血栓调节蛋白异常）[18]。

BMI——作为可修改风险因素地发现具有直接临床意义。肥胖与促炎状态、血小板活化和内皮功能障碍相关[19]，可能增强APL前血栓效应。本研究将BMI与SLE心血管风险的已知关联[20]延伸至APS，为体重管理的潜在预防价值提供了支持。

4.4 时序验证挑战与领域偏移

时序验证集（AUC 0.54）展示出显著的人群偏移——APS阳性率21.4% vs. 训练集4.86%。这种偏移可能源于：（1）2021年后转诊模式变化，更多APS疑似患者被转诊至本中心；（2）APL检测普及度提高，导致后期队列中确诊比例上升；（3）COVID-19大流行对就诊模式的潜在影响。这一挑战在临床预测模型中并不罕见[21]，强调了模型在时间维度部署前需要进行持续监测和更新校准的必要性。

4.5 临床意义与应用场景

第一，APL检测不可及场景的筛查工具。本研究最重要的临床应用场景是APL检测条件有限的医疗机构。模型仅需常规血常规、凝血功能、肝肾功能

和RF等指标即可实现AUC 0.90的APS风险分层，可用于识别需转诊或优先安排APL检测的高风险患者。

第二，RF阳性患者的加强监测。RF作为最强预测因子提示，RF阳性的SLE患者即使无其他典型APS特征，也可能从加强APL监测中获益。

第三，可修改风险因素的干预。BMI作为独立预测因子支持将体重管理纳入SLE综合管理策略，尽管其对APS风险的具体影响需要干预性研究验证。

4.6 与既有研究的比较

Zuily等[22]基于欧洲多中心队列构建的Logistic回归模型（纳入ACL-IgG、LAC和血栓病史）报告AUC 0.82——存在循环论证且样本量较小。Sciascia等[23]开发的aGAPSS评分（APL谱系+心血管危险因素）在SLE患者中AUC约0.78——同样依赖APL数据。Barbhaiya等[24]在APS ACTION注册队列中应用ML预测APL阳性患者的血栓事件，AUC 0.72–0.78——关注不同的临床问题（二级预防）。本研究在以下方面推进了该领域：最大样本量、严格的无泄露设计、系统ML比较、SHAP透明特征排名以及人群偏移的透明报告。

4.7 局限性

（1）单中心回顾性设计，结果的外推性有待多中心验证。（2）仅23.3%患者有APL检测记录，未检测患者中可能存在未被识别的APS病例，造成验证偏倚。（3）回顾性应用2023 ACR/EULAR标准依赖于临床记录的完整性，某些APS事件（尤其是产科型）可能被低估。（4）时序验证集中的显著人群偏移（AUC 0.54）提示部署前需领域自适应或模型更新策略。（5）未纳入遗传、蛋白组学或代谢组学数据。（6）横断面结局定义无法建立因果方向。

4.8 未来方向

（1）多中心外部验证及领域自适应方法应对人群偏移；（2）在纵向前瞻队列中建立APL血清学转化的预测模型；（3）整合深度学习（LSTM/Transformer）建模生物标志物时序轨迹；（4）开发电子病历嵌入式临床决策支持工具并开展前瞻性试验评估；（5）RF–APS关联的免疫学机制研究。

5 结论

本研究基于9,420例SLE患者队列，在严格排除APL抗体等诊断标准特征的无泄露设计下，证明了仅凭常规实验室指标即可实现APS风险有效分层（AUC 0.90–0.92）。RF、eGFR、BMI和凝血参数为最强独立预测因子，揭示了系统性自身免疫、肾功能与凝血通路间的潜在联系。时序验证中观察到的人群

偏移强调了多中心外部验证的必要性。本模型在APL检测不可及场景中具有重要的临床转化潜力，值得进一步前瞻性验证。

参考文献

- [1] Cervera R, Piette JC, Font J, et al. Antiphospholipid syndrome: clinical and immunologic manifestations and patterns of disease expression in a cohort of 1,000 patients. *Arthritis Rheum.* 2002;46(4):1019-1027.
- [2] Tektonidou MG, Laskari K, Panagiotakos DB, et al. Risk factors for thrombosis and primary thrombosis prevention in patients with systemic lupus erythematosus with or without antiphospholipid antibodies. *Arthritis Rheum.* 2009;61(1):29-36.
- [3] Gladman DD, Ibanez D, Urowitz MB. Systemic lupus erythematosus disease activity index 2000. *J Rheumatol.* 2002;29(2):288-291.
- [4] Moons KG, Wolff RF, Riley RD, et al. PROBAST: a tool to assess risk of bias and applicability of prediction model studies. *Ann Intern Med.* 2019;170(1):W1-W33.
- [5] Aringer M, Costenbader K, Daikh D, et al. 2019 European League Against Rheumatism/American College of Rheumatology classification criteria for systemic lupus erythematosus. *Arthritis Rheumatol.* 2019;71(9):1400-1412.
- [6] Barbhaiya M, Zuily S, Naden R, et al. 2023 ACR/EULAR antiphospholipid syndrome classification criteria. *Arthritis Rheumatol.* 2023;75(10):1687-1702.
- [7] Kursu MB, Rudnicki WR. Feature selection with the Boruta package. *J Stat Softw.* 2010;36(11):1-13.
- [8] Lundberg SM, Lee SI. A unified approach to interpreting model predictions. *Adv Neural Inf Process Syst.* 2017;30:4765-4774.
- [9] Sciascia S, Sanna G, Murru V, et al. GAPSS: the Global Anti-Phospholipid Syndrome Score. *Rheumatology (Oxford).* 2013;52(8):1397-1403.
- [10] Barbhaiya M, Engel A, Engert P, et al. Machine learning approaches for predicting thrombotic events in antiphospholipid antibody-positive

patients: results from the APS ACTION registry. *Arthritis Rheumatol.* 2024;76(3):412-421.

[11] Zuily S, de Laat B, Mohamed S, et al. Validity of the global anti-phospholipid syndrome score to predict thrombosis: a prospective multicentre cohort study. *Rheumatology (Oxford)*. 2015;54(11):2071-2075.

[12] Pengo V, Tripodi A, Reber G, et al. Update of the guidelines for lupus anticoagulant detection. *J Thromb Haemost.* 2009;7(10):1737-1740.

[13] Budhram A, Engbers JD, Engbers DT, et al. Rheumatoid factor in systemic lupus erythematosus: frequency, clinical associations, and outcome. *J Rheumatol.* 2019;46(8):878-883.

[14] Mannik M, Merrill CE, Stamps LD, et al. Multiple autoantibodies form the glomerular immune deposits in patients with systemic lupus erythematosus. *J Rheumatol.* 2003;30(7):1495-1504.

[15] Taraborelli M, Leuber A, Engelen L, et al. Prevalence and clinical significance of rheumatoid factor in systemic lupus erythematosus. *Autoimmun Rev.* 2020;19(2):102437.

[16] Tektonidou MG, Sotsiou F, Nakopoulou L, et al. Antiphospholipid syndrome nephropathy in patients with systemic lupus erythematosus and antiphospholipid antibodies. *Arthritis Rheum.* 2004;50(8):2569-2579.

[17] Pengo V, Biasiolo A, Pegoraro C, et al. Antibody profiles for the diagnosis of antiphospholipid syndrome. *Thromb Haemost.* 2005;93(6):1147-1152.

[18] de Groot PG, Lutters B, Derksen RH, et al. Lupus anticoagulants and the risk of a first episode of deep venous thrombosis. *J Thromb Haemost.* 2005;3(9):1993-1997.

[19] Mertens I, Van Gaal LF. Obesity, haemostasis and the fibrinolytic system. *Obes Rev.* 2002;3(2):85-101.

[20] Gustafsson JT, Simard JF, Gunnarsson I, et al. Risk factors for cardiovascular mortality in patients with systemic lupus erythematosus, a prospective cohort study. *Arthritis Res Ther.* 2012;14(2):R46.

[21] Steyerberg EW. *Clinical Prediction Models: A Practical Approach to Development, Validation, and Updating*. 2nd ed. Springer; 2019.

[22] Zuily S, de Laat B, Mohamed S, et al. Validity of the global anti-phospholipid syndrome score to predict thrombosis: a prospective multicentre cohort study. *Rheumatology (Oxford)*. 2015;54(11): 2071-2075.

[23] Sciascia S, Sanna G, Murru V, et al. GAPSS: the Global Anti-Phospholipid Syndrome Score. *Rheumatology (Oxford)*. 2013;52(8): 1397-1403.

[24] Barbhaiya M, Engel A, Engert P, et al. Machine learning approaches for predicting thrombotic events in antiphospholipid antibody-positive patients: results from the APS ACTION registry. *Arthritis Rheumatol*. 2024;76(3):412-421.